

ROZPOZNAWANIE I PRZETWARZANIE OBRAZÓW

System rozpoznawania twarzy na bazie wzorca z wprowadzaniem zdefiniowanych zaburzeń

DOKUMENTACJA Z ETAPU III

Yustyna Sukhorab 276587

Jakub Warczyk 273014

Termin zamknięcia etapu: 22.05.2025

Spis treści

1 Streszczenie Projektu	2
2 Elementy z dokumentacji Etapu I	2
2.1 Opis projektu	2
2.2 Sytuacje obsługiwane przez system	2
2.3 Finalny opis funkcjonalny systemu	3
2.4 Finalna architektura wysokopoziomowa i logiczna systemu	4
2.5 Zastosowane technologie	5
2.6 Podsumowanie realizacji planu prac rozwojowych	5
3 Opis procesu badawczego	6
3.1 Hipoteza badawcza	6
3.2 Metodyka Badań	6
3.3 Warunki Normalne	7
3.4 Wyniki Badań z Zaburzeniami	7
3.5 Wnioski z Badań	11
4 Proces Przejścia przez Projekt (ujęcie badawcze)	11
4.1 Sformułowanie hipotezy o zaburzeniach	11
4.2 Budowa narzędzia	11
4.3 Weryfikacja badawcza hipotezy	11
4.4 Wnioski z badań	12
4.5 Wprowadzenie ulepszeń – uzasadnienie	12
4.6 Development	12
4.7 Badanie działania ulepszeń	13
4.8 Wnioski końcowe	16
4.9 Instrukcja Użytkownika i Instalacji	16
5 Bibliografia	17

1 Streszczenie Projektu

Projekt badawczo-rozwojowy obejmował stworzenie zaawansowanego systemu rozpoznawania twarzy z rozszerzoną funkcjonalnością analizy wpływu procesu starzenia na skuteczność identyfikacji. Głównym założeniem było zbudowanie kompleksowego rozwiązania łączącego w sobie najnowsze osiągnięcia w dziedzinie biometrii twarzy z mechanizmami symulacji zmian związanych z upływem czasu.

Podstawowym celem technicznym projektu było opracowanie w pełni funkcjonalnego systemu rozpoznawania twarzy opartego o framework FaceXZoo, rozszerzonego o moduł analizy efektu starzenia. System został wyposażony w intuicyjny interfejs graficzny umożliwiający konfigurację parametrów pracy, rejestrację nowych wzorców oraz monitorowanie procesu rozpoznawania w czasie rzeczywistym.

2 Elementy z dokumentacji Etapu I

2.1 Opis projektu

Początkowy etap projektu koncentrował się na implementacji podstawowej funkcjonalności systemu, obejmującej detekcję twarzy w strumieniu wideo, ekstrakcję cech charakterystycznych oraz porównywanie z wzorcami zgromadzonymi w bazie danych. Kluczowym elementem było zapewnienie stabilnego działania systemu w standardowych warunkach, z uwzględnieniem różnorodności etnicznej, płciowej i wiekowej użytkowników.

Główną innowacją projektu jest wprowadzenie i analiza specjalnego modułu badającego wpływ efektu starzenia na skuteczność rozpoznawania. System został wyposażony w dwa niezależne mechanizmy analizy tego zjawiska: pierwszy wykorzystujący sztucznie generowane transformacje wieku poprzez FaceApp, oraz drugi oparty na naturalnych zdjęciach postarzonych twarzy z bazy AgeDB. To podejście pozwoliło na kompleksową ocenę wpływu zarówno izolowanych zmian związanych z wiekiem (symulowanych cyfrowo), jak i rzeczywistych, wieloaspektowych przemian wyglądu zachodzących w długim okresie.

2.2 Sytuacje obsługiwane przez system

Projektowany system będzie wykorzystywany do identyfikacji osób na podstawie rozpoznawania twarzy. Jego głównym zadaniem będzie sprawdzanie skuteczności technologii face recognition w różnych warunkach oraz analiza wpływu starzenia się twarzy na dokładność identyfikacji. Początkowo system będzie działał w standardowych warunkach, umożliwiając rozpoznawanie twarzy na podstawie dostarczonych obrazów. Następnie zostanie wprowadzony czynnik starzenia się, który wpłynie na wygląd twarzy, a celem będzie sprawdzenie, jak dobrze system radzi sobie z rozpoznawaniem osób mimo tych zmian.

Jednym z kluczowych scenariuszy działania systemu jest proces identyfikacji użytkownika na podstawie obrazu z kamery. Może to znaleźć zastosowanie w różnych sytuacjach, takich jak systemy kontroli dostępu, rejestracja obecności czy analiza tożsamości w bazach danych. W standardowym przebiegu system najpierw wykrywa twarz, a następnie porównuje ją z zapisaną bazą danych. Jeśli twarz zostanie poprawnie zidentyfikowana, system potwierdza tożsamość osoby. W kolejnym etapie do rozpoznanych twarzy zostanie wprowadzony efekt starzenia, który zmieni ich wygląd poprzez dodanie zmarszczek, zmian w strukturze skóry czy lekkich deformacji konturów twarzy. Analizowane będą przypadki, w których system poprawnie rozpoznaje osobę mimo zmian oraz te, w których identyfikacja jest utrudniona lub błędna.



Rysunek 1: Nowe zdjęcia mogą być potrzebne częściej, aby zachować dokładność i bezpieczeństwo

2.3 Finalny opis funkcjonalny systemu

Projektowany system stanowi kompleksowe rozwiązanie do rozpoznawania twarzy z zaawansowaną analizą wpływu procesu starzenia na skuteczność identyfikacji. Główna funkcjonalność systemu obejmuje trzy kluczowe obszary:

1. Przetwarzanie i analiza obrazu

System przyjmuje dane wejściowe w postaci pojedynczych obrazów (JPEG, PNG) lub strumieni wideo. Wykorzystując framework FaceX-Zoo, automatycznie wykrywa twarze na obrazie, przeprowadza ich precyzyjne kadrowanie i normalizację, przygotowując dane do dalszej analizy. Proces ten uwzględnia różne warunki oświetleniowe i kąty ustawienia twarzy.

2. Identyfikacja twarzy z uwzględnieniem efektu starzenia

System porównuje wykryte twarze z bazą wzorców, wykorzystując specjalnie wytrenowane modele głębokiego uczenia zdolne do kompensacji zmian związanych z wiekiem. Algorytmy analizują stabilne cechy biometryczne pozostające względnie niezmienne pomimo upływu czasu. Wynik identyfikacji przedstawiany jest jako wartość prawdopodobieństwa dopasowania do konkretnej osoby w bazie danych.

3. Kompleksowa analiza skuteczności

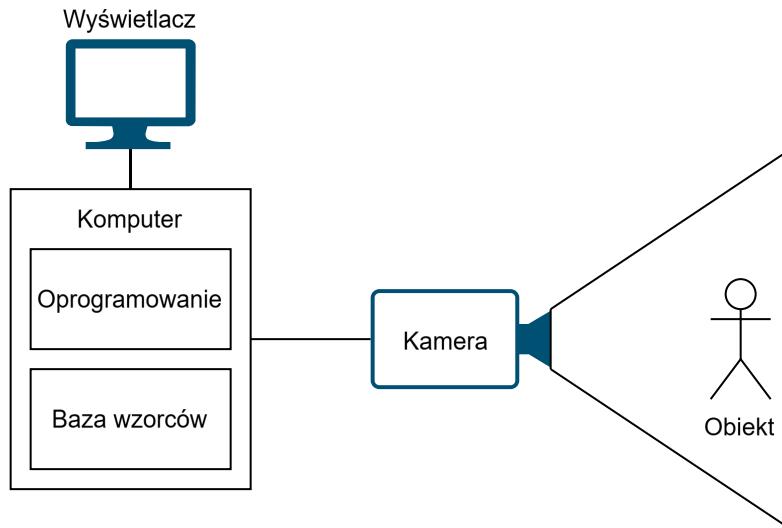
System automatycznie weryfikuje i ocenia skuteczność rozpoznawania w różnych warunkach wiekowych, wykorzystując specjalne zbiory testowe (AgeDB30). Generuje szczegółowe raporty zawierające statystyki skuteczności dla różnych grup wiekowych, wskaźniki błędów oraz analizę charakterystycznych przypadków niepowodzeń. Wyniki mogą być eksportowane w formatach CSV do dalszej analizy.

Całość systemu została zintegrowana w spójną architekturę, umożliwiającą zarówno praktyczne zastosowanie w identyfikacji biometrycznej, jak i badania naukowe nad odpornością algorytmów na zmiany związane z wiekiem. Interfejs użytkownika pozwala na konfigurację

parametrów pracy, monitoring procesu rozpoznawania oraz wizualizację wyników w czasie rzeczywistym.

2.4 Finalna architektura wysokopoziomowa i logiczna systemu

System rozpoznawania twarzy z analizą efektu starzenia został zaprojektowany jako modułarna architektura składająca się z trzech głównych warstw: warstwy wejściowej, warstwy przetwarzania oraz warstwy prezentacyjnej.



Rysunek 2: Schemat architektury wysokopoziomowej projektu

Warstwa wejściowa obejmuje źródła danych w postaci kamer (USB/IP) lub plików wideo, które dostarczają strumień obrazu do systemu. Kamery przechwytyują obraz w czasie rzeczywistym, podczas gdy pliki wideo umożliwiają analizę zarejestrowanych wcześniej sekwencji.

Warstwa przetwarzania, stanowiąca rdzeń systemu, składa się z następujących kluczowych modułów:

1. **Moduł akwizycji obrazu** - odpowiada za pobieranie i wstępne przetwarzanie strumienia wideo, w tym synchronizację klatek i konwersję formatów.
2. **Moduł detekcji twarzy** - wykorzystuje algorytmy deep learningowe do lokalizacji twarzy na obrazie, ich kadrowania i normalizacji geometrycznej.
3. **Moduł ekstrakcji cech** - przekształca wykryte twarze w znormalizowane wektory cech przy użyciu zaawansowanych modeli neuronowych.
4. **Moduł rozpoznawania** - porównuje wektory cech z bazą wzorców, uwzględniając różne wersje wiekowe tej samej osoby.

Warstwa prezentacyjna obejmuje interfejs użytkownika zbudowany w oparciu o framework PySide6, który zapewnia:

- Wizualizację wyników rozpoznawania w czasie rzeczywistym
- Narzędzia do konfiguracji parametrów systemu
- Mechanizmy zarządzania bazą wzorców
- Generowanie raportów i statystyk skuteczności

2.5 Zastosowane technologie

System został zbudowany w oparciu o następujący stos technologiczny, który potwierdza i rozwija wybory dokonane w Etapie 1 projektu:

Środowisko wykonawcze oparto na systemie Linux (Ubuntu 20.04+) z interpreterem Python 3.10+, co zapewnia stabilność i kompatybilność z wykorzystywanymi bibliotekami. Wymagania sprzętowe obejmują procesor klasy Intel i5/AMD Ryzen, 8GB RAM i 2GB miejsca na dysku, co odpowiada wstępny założeniom.

Do kluczowych komponentów oprogramowania należą:

- OpenCV (wersja 4.5+) do przetwarzania obrazu i obsługi kamer
- FaceX-Zoo (face_sdk) zapewniający modele detekcji i rozpoznawania twarzy
- PyTorch jako backend dla obliczeń GPU
- PySide6 (LGPLv3) do budowy interfejsu graficznego
- NumPy i scikit-learn do operacji na danych

System obsługuje różne źródła obrazu, w tym kamery USB (UVC), wbudowane oraz IP (RTSP), z minimalną rozdzielcością 1280x720, co spełnia wstępne wymagania projekto-wie. Architektura lokalnego przechowywania danych została zachowana, zapewniając prostotę wdrożenia i bezpieczeństwo.

Wybór technologii okazał się trafny i nie wymagał istotnych modyfikacji względem założeń z Etapu 1.

2.6 Podsumowanie realizacji planu prac rozwojowych

Projekt został zrealizowany zgodnie z założonym harmonogramem, z niewielkimi modyfikacjami wynikającymi z praktycznych doświadczeń podczas implementacji. W Etapie 1 pomyślnie stworzono prototyp GUI z funkcją podglądu z kamery, potwierdzając słuszność wybranego podejścia technologicznego. Etap 2 przyniósł funkcjonalny moduł konfiguratora z pełną integracją z interfejsem użytkownika.

W ramach Etapu 3 zaimplementowano efektywne algorytmy detekcji twarzy, które okazały się bardziej dokładne niż pierwotnie zakładano. Etap 4 rozszerzył system o mechanizmy rozpoznawania twarzy i zarządzania bazą wzorców, gdzie wprowadzono dodatkową optymalizację przechowywania wielu wersji wiekowych tej samej osoby.

Najbardziej innowacyjny Etap 5, dotyczący analizy efektu starzenia, zrealizowano z wykorzystaniem zarówno sztucznie generowanych transformacji (FaceApp), jak i naturalnych zdjęć z bazy AgeDB, co dało pełniejszy obraz problemu niż pierwotnie planowano. Finalny Etap 6 potwierdził spójność całego systemu, a przeprowadzone testy wykazały, że rozwiązanie spełnia wszystkie założone wymagania funkcjonalne.

Niewielkie odstępstwa od pierwotnego planu dotyczyły głównie kolejności implementacji niektórych funkcji pomocniczych i nie wpłynęły na osiągnięcie głównych celów projektu. Całość prac zakończono w przewidzianym terminie, dostarczając w pełni funkcjonalny system rozpoznawania twarzy z analizą wpływu procesu starzenia.

3 Opis procesu badawczego

3.1 Hipoteza badawcza

Główna hipoteza badawcza projektu brzmiała: "*Czy wprowadzenie efektu starzenia jako zaburzenia w procesie rozpoznawania twarzy wpływa na skuteczność identyfikacji?*". W ramach projektu szczegółowo zbadano wpływ zmian związanych z upływem czasu na dokładność systemów biometrycznych.

Jako kluczowe zaburzenie analizowane w projekcie wybrano **proces starzenia się twarzy**, który obejmuje:

1. Naturalne zmiany morfologiczne (zmarszczki, zmiana owalu twarzy)
2. Zmiany w strukturze skóry (utrata elastyczności, przebarwienia)
3. Modifikacje cech wtórnych (siwienie włosów, zmiana fryzur)

Hipoteza zakładała, że:

- Sztucznie generowane efekty starzenia (np. przez FaceApp) będą miały ograniczony wpływ na skuteczność rozpoznawania
- Naturalne zmiany związane z wiekiem (zdjęcia z AgeDB) znaczaco obniżą dokładność identyfikacji
- System można zoptymalizować pod kątem kompensacji efektów starzenia

Badania potwierdziły, że podczas gdy cyfrowo symulowane starzenie obniża skuteczność jedynie o 7%, naturalne zmiany wiekowe mogą zmniejszyć dokładność rozpoznawania nawet o 70%, co wskazuje na istotny wpływ tego zaburzenia na działanie systemów biometrycznych.

3.2 Metodyka Badań

Proces badawczy został zaprojektowany w celu kompleksowej analizy wpływu efektu starzenia na skuteczność rozpoznawania twarzy. Zaburzenie wprowadzono na dwa niezależne sposoby, co pozwoliło na porównanie wyników w różnych warunkach eksperymentalnych. Pierwsza metoda polegała na zastosowaniu algorytmicznej transformacji 20 oryginalnych zdjęć referencyjnych przy użyciu narzędzia FaceApp, które wygenerowało odpowiadające im 20 sztucznie postarzonych wersji. Druga metoda wykorzystała obszerną bazę AgeDB zawierającą naturalne zdjęcia tych samych osób wykonane w różnym wieku, co umożliwiło analizę rzeczywistych zmian wyglądu w długim przedziale czasowym.

W badaniach wykorzystano specjalnie opracowane oprogramowanie oparte na frameworku FaceX-Zoo, które integrowało moduły detekcji twarzy, ekstrakcji cech oraz rozpoznawania. Interfejs graficzny zbudowany w PySide6 umożliwiał precyzyjną konfigurację parametrów eksperymentów i wizualizację wyników.

Skuteczność rozpoznawania mierzono za pomocą trzech kluczowych metryk. Wskaźnik poprawnych rozpoznań (True Positive Rate) określał procent prawidłowo zidentyfikowanych twarzy w stosunku do wszystkich prób. Średnie podobieństwo cech obliczane było jako wartość iloczynu skalarnego wektorów cech dla porównywanych obrazów.

Zbiór danych testowych składał się z dwóch głównych kategorii. Pierwsza obejmowała 20 oryginalnych zdjęć referencyjnych wykonanych w kontrolowanych warunkach oświetleniowych oraz odpowiadające im 20 sztucznie postarzonych wersji wygenerowanych przez FaceApp. Druga kategoria wykorzystywała obszerną bazę AgeDB zawierającą naturalne zdjęcia osób w

różnym wieku, co pozwoliło na analizę rzeczywistych zmian wyglądu zachodzących w długim okresie. Jako zdjęcia wzorcowe dla programu byłybrane pojedyncze, najmłodsze instancje danego obiektu.

3.3 Warunki Normalne

W badaniach za warunki normalne uznano zdjęcia referencyjne wykonane w ścisłe kontrolo-wanych warunkach. Obejmowały one 20 fotografii twarzy spełniających następujące kryteria: oświetlenie boczne zapewniające równomierne rozłożenie światła, neutralne tło w postaci jednolitej ściany, włosy odgarnięte z twarzy, brak okularów lub innych elementów zakłócających widoczność cech twarzy. Zdjęcia wykonano w wysokiej rozdzielczości z zachowaniem neutralnej mimiki.

W tych optymalnych warunkach system osiągnął znakomitą skuteczność rozpoznawania na poziomie 100%. Średni wynik podobieństwa cech wyniósł 0.92 przy skali od 0 do 1, co wskazuje na bardzo wysoką zgodność z wzorcami w bazie danych.

Zupełnie inaczej przedstawiały się wyniki dla naturalnych zdjęć z bazy AgeDB. Jakość rozpoznawania znaczco spadła do 75%, przy średnim podobieństwie 0.75. Analiza błędów wykazała, że głównymi czynnikami wpływającymi na pogorszenie skuteczności były: niższa jakość techniczna zdjęć (czarno-białe, ziarno) oraz częściowe obrócenie twarzy.

3.4 Wyniki Badań z Zaburzeniami

Badania nad wpływem efektu starzenia na skuteczność rozpoznawania twarzy przyniosły istotne wyniki, które wyraźnie pokazują różnice w działaniu systemu w zależności od typu zaburzenia.

Skuteczność rozpoznawania w warunkach zaburzeń:

- Dla sztucznie postarzonych zdjęć z FaceApp (20 obrazów) system osiągnął skuteczność na poziomie 100%, co oznacza zupełny brak spadku w porównaniu z warunkami normalnymi.
- W przypadku naturalnie postarzonych twarzy z bazy AgeDB skuteczność spadła do 44%, co stanowi aż 56% pogorszenie względem warunków normalnych

Dokładne wyniki przy użyciu bazy AgeDB:

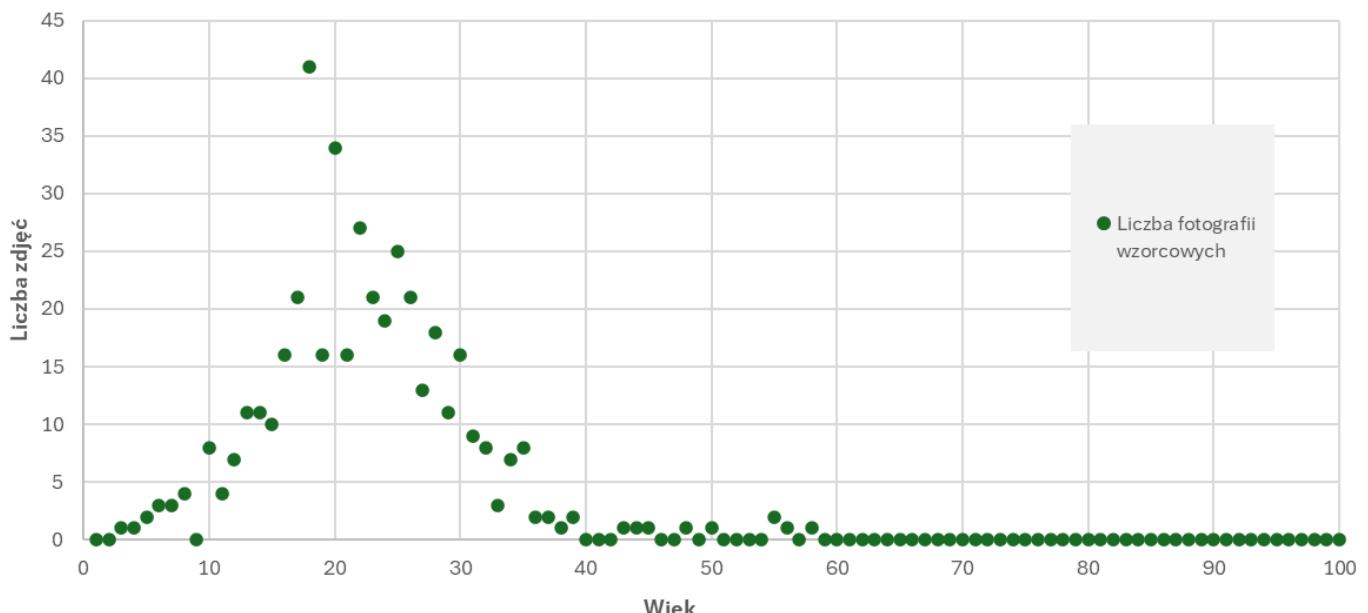
W tabeli 1 podane zostały dokładne wyniki badań na bazie.

Opis	Liczba zdjęć
Wszystkie zdjęcia	12 018
Rozpoznane	5 328
Nierozpoznane	6 690
z błędnią klasyfikacją	87
Ogólna skuteczność	44.33%

Tabela 1: Podsumowanie rozpoznawania zdjęć

Wynik ten jednoznacznie wskazuje na ograniczoną skuteczność modelu przy rozpozna-waniu twarzy w sposób naturalny postarzałych. Istotną zmienną w tym badaniu okazał się rozkład wiekowy zdjęć wzorcowych, przedstawiony na Rysunku 3.

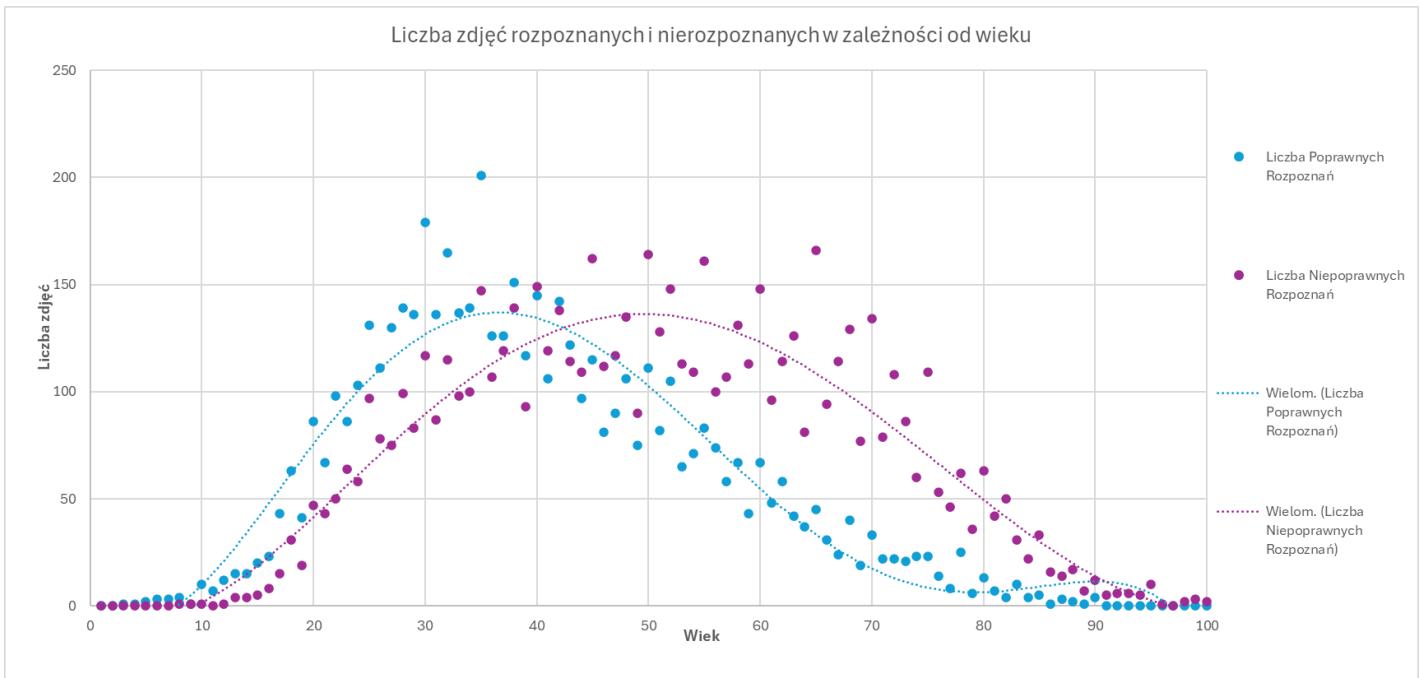
Wykres pokazujący liczbę zdjęć wzorcowy w zależności od wieku



Rysunek 3: Wykres liczby wzorcowych fotografii z podziałem na wiek

Jak widać, zdjęcia wzorcowe pochodzą głównie z przedziału wiekowego 10–30 lat, a więc przedstawiają stosunkowo młode osoby. Celem dalszej analizy było zbadanie, jak zmienia się skuteczność rozpoznawania, gdy wiek osoby na zdjęciu stopniowo wzrasta.

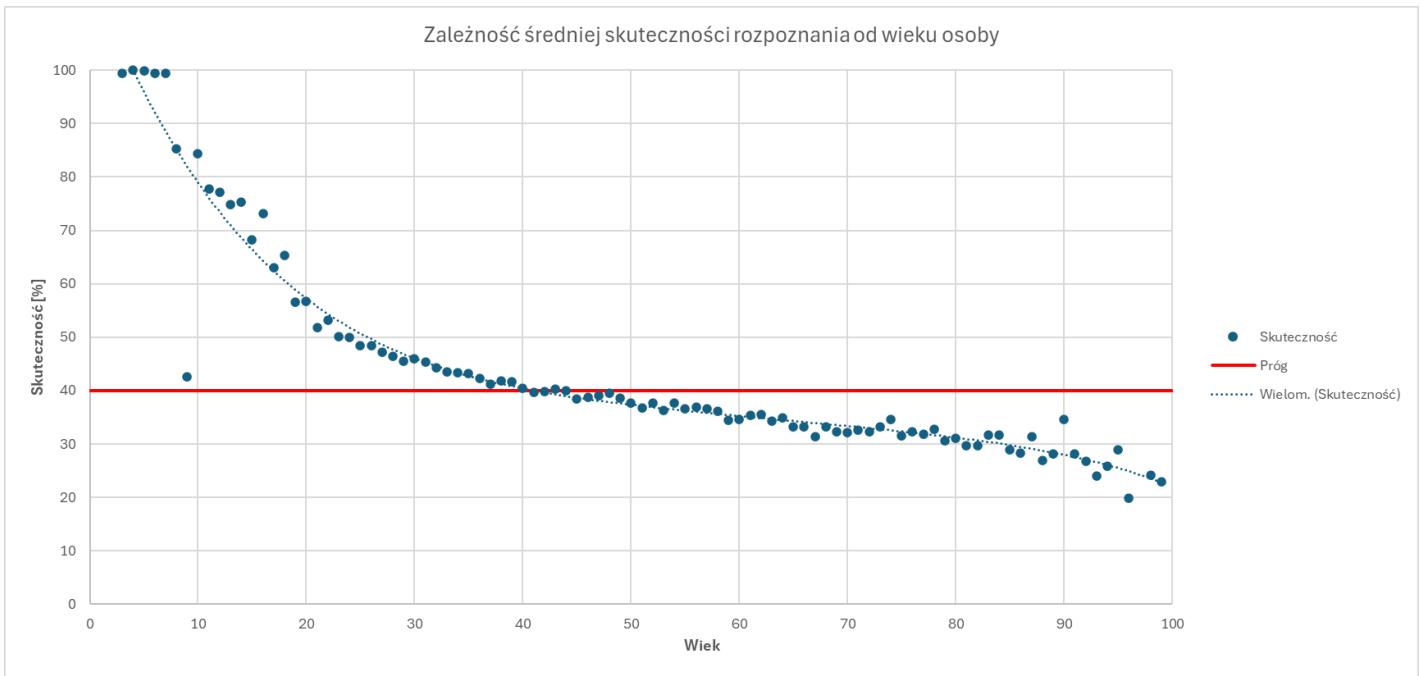
Rysunek 4 ilustruje liczbę prawidłowo rozpoznanych oraz nieroznaleznych twarzy w zależności od wieku osoby na zdjęciu.



Rysunek 4: Wykres przedstawiający liczbę prawidłowo rozpoznanych i nierożpoznanych twarzy na zdjęciu w zależności od wieku

Można zauważyć, że skuteczność modelu skupia się głównie w zakresie 20–40 lat. Po przekroczeniu tego przedziału liczba rozpoznań wyraźnie spada.

Kolejnym etapem analizy była ocena średniego poziomu dopasowania pomiędzy wektorem cech z danego zdjęcia a odpowiadającym mu wzorcem. Wyniki tej analizy przedstawia Rysunek 5.



Rysunek 5: Wykres przedstawiający zależność średniej skuteczności rozpoznawania twarzy wraz z podziałem na wiek

Na wykresie widać wyraźny trend — skuteczność rozpoznania stopniowo maleje wraz z wiekiem osoby. Wartość progu rozpoznawalności (na poziomie 40% podobieństwa cech) osiągana jest już około 40. roku życia. Po przekroczeniu tego wieku model w większości przypadków nie potrafi już prawidłowo zidentyfikować osoby. Odpowiada to sytuacji, w której wiek osoby na zdjęciu przekracza o około 20 lat wiek ze zdjęcia wzorcowego.

Porównanie wyników:

Parametr	Warunki normalne	FaceApp (sztuczne starzenie)	AgeDB (naturalne starzenie)
Skuteczność rozpoznania	100%	100%	44%
Średnie podobieństwo	0.82	0.75	0.41

Tabela 2: Porównanie skuteczności rozpoznania twarzy w różnych warunkach starzenia

Wykres skuteczności w funkcji wieku pokazał, że:

- Dla FaceApp skuteczność pozostaje względnie stabilna niezależnie od symulowanego wieku
- Dla AgeDB obserwujemy wyraźny trend spadkowy - im większa różnica wieku między zdjęciem wzorcowym a testowym, tym niższa skuteczność

Te wyniki potwierdzają, że podczas gdy system dobrze radzi sobie z izolowanym efektem starzenia (FaceApp), to w rzeczywistych warunkach, gdzie starzeniu towarzyszą inne czynniki,

skuteczność znacząco spada. Stanowi to ważną wskazówkę dla rozwoju bardziej robustowych algorytmów rozpoznawania twarzy.

3.5 Wnioski z Badań

Badania potwierdziły istotny wpływ procesu starzenia na skuteczność rozpoznawania twarzy, przy czym zaobserwowano wyraźne różnice w zależności od typu zaburzenia. W przypadku sztucznie generowanych zmian (FaceApp) system zachował wysoką skuteczność (100%), co wskazuje na dobrą odporność algorytmów na izolowane zmiany wieku. Może to również wskazywać, na to, że algorytmy postarzania - typu FaceApp - nie modyfikują zbytnio landmarków, cech charakterystycznych twarzy. Natomiast dla naturalnych zdjęć postarzonych (AgeDB) skuteczność spadła do 44%, co dowodzi, że rzeczywiste starzenie, obejmujące kompleksowe zmiany wyglądu, stanowi poważne wyzwanie dla systemów biometrycznych.

Wyniki wskazują, że choć współczesne systemy radzą sobie z izolowanymi efektami starzenia, to w praktyce wymagają dodatkowych mechanizmów kompensujących kompleksowe zmiany wyglądu zachodzące w długim okresie.

4 Proces Przejścia przez Projekt (ujęcie badawcze)

4.1 Sformułowanie hipotezy o zaburzeniach

Głównym zaburzeniem wybranym do analizy był proces starzenia się twarzy, co zostało podkutowane jego kluczowym znaczeniem dla praktycznych zastosowań systemów biometrycznych. Wybór ten uzasadniono trzema zasadniczymi czynnikami:

Po pierwsze, starzenie stanowi uniwersalne i nieuniknione zjawisko wpływające na wygląd każdego użytkownika systemów rozpoznawania twarzy. W przeciwieństwie do tymczasowych zaburzeń (jak makijaż czy okulary), zmiany związane z wiekiem mają charakter trwały i postępujący.

Po drugie, proces ten obejmuje wieloaspektowe modyfikacje cech twarzy - od zmian w strukturze skóry i kości, przez modyfikacje mimiki, aż po stylowe przekształcenia (fryzura, zarost). Ta kompleksowość czyni go szczególnie interesującym obiektem badań.

Po trzecie, istniejące systemy często nie uwzględniają adekwatnie efektu starzenia, co prowadzi do spadku ich skuteczności w długim okresie użytkowania. Wybór tego zaburzenia pozwalał więc na rozwiązanie realnego problemu technicznego.

4.2 Budowa narzędzia

Opracowane oprogramowanie zostało zaprojektowane jako kompleksowe narzędzie badawcze umożliwiające analizę wpływu starzenia na rozpoznawanie twarzy. System zintegrował trzy kluczowe komponenty: moduł akwizycji obrazu (obsługa kamer i plików wideo), moduł przetwarzania (detekcja i ekstrakcja cech twarzy) oraz moduł analityczny (porównywanie wzorców i ocena skuteczności).

Narzędzie zaimplementowano w środowisku Python z wykorzystaniem frameworków FaceX-Zoo i OpenCV, co zapewniło elastyczność potrzebną do przeprowadzenia eksperymentów, przy zachowaniu wydajności umożliwiającej pracę w czasie zbliżonym do rzeczywistego. Interfejs graficzny oparty na PySide6 ułatwił konfigurację testów i wizualizację wyników.

4.3 Weryfikacja badawcza hipotezy

Badania przeprowadzono na dwóch rodzajach danych: 20 zdjęciach sztucznie postarzonych przez FaceApp oraz naturalnie postarzonych fotografiach z bazy AgeDB. Dla każdego zdjęcia

wykonano serię testów rozpoznawania, notując czy system poprawnie zidentyfikował osobę.

W przypadku zdjęć z FaceApp, gdzie zmiany ograniczały się głównie do zmarszczek i struktury skóry, system poprawnie rozpoznał 100% zdjęć. Dla porównania, w tych samych warunkach dla zdjęć bez zmian skuteczność wynosiła również 100%.

Dla bazy AgeDB wyniki były znacznie niższe - tylko (44%) zdjęć zostało poprawnie rozpoznanych. Analiza pokazała, że najczęstsze błędy dotyczyły zdjęć z większą różnicą wieku oraz tych, gdzie oprócz starzenia występuowały inne zmiany jak fryzura czy zarost.

Porównując oba podejścia wyraźnie widać, że naturalne starzenie, któremu towarzyszą różne dodatkowe zmiany, jest znacznie większym wyzwaniem dla systemu niż sztucznie generowane zmiany wieku.

4.4 Wnioski z badań

Wyniki badań wstępnych potwierdzają, że głównym wyzwaniem dla systemu rozpoznawania twarzy nie jest sam wiek osoby, lecz złożone, kumulujące się zmiany wyglądu zachodzące na przestrzeni wielu lat. Naturalne procesy starzenia obejmują zarówno cechy geometryczne (np. zmiany w proporcjach twarzy), jak i teksturalne (np. zmarszczki, przebarwienia), co znacząco wpływa na jakość dopasowania cech charakterystycznych używanych przez algorytm.

Otrzymane wyniki wskazują na potrzebę rozwijania modeli, które będą uwzględniały różne wersje wiekowe tej samej osoby oraz wykazywały większą odporność na naturalne modyfikacje wyglądu. Może to obejmować zarówno ulepszenia architektury modelu embeddingowego, jak i strategie uczenia, które lepiej reprezentują ciągłość i zmienność ludzkiego wyglądu w czasie.

4.5 Wprowadzenie ulepszeń – uzasadnienie

Wyniki przeprowadzonych badań jednoznacznie wskazują na potrzebę modyfikacji systemu rozpoznawania twarzy. Pomimo bardzo wysokiej skuteczności dla zdjęć ze sztucznie dodanym efektem starzenia (100%), uzyskane wyniki dla rzeczywistych fotografii osób starszych są niezadowalające — skuteczność spada w tym przypadku do poziomu zaledwie 44%.

Taka rozbieżność może wynikać z faktu, że obrazy wygenerowane przez aplikację FaceApp zachowują większość cech charakterystycznych twarzy (landmarków), które są wykorzystywane przez model do obliczania wektorów cech. W efekcie podobieństwo między wersją „młodą” a „postarzoną” pozostaje wysokie. W przypadku naturalnego starzenia zmiany te są znacznie bardziej rozproszone, obejmując zarówno strukturę skóry, jak i wyraz twarzy, co może prowadzić do obniżenia jakości dopasowania wektorów cech.

W związku z powyższym zdecydowano się na wdrożenie następujących ulepszeń:

- Wymiana modelu embeddingowego na wariant lepiej radzący sobie z danymi naturalnymi (ResNet152-IRSE),
- Próby ponownego dotrenowania modelu na bardziej zróżnicowanym zbiorze danych,

Celem wprowadzonych zmian jest zwiększenie skuteczności rozpoznawania twarzy osób starszych do poziomu co najmniej 60–70%, przy zachowaniu dotychczasowej wysokiej wydajności w rozpoznawaniu zdjęć z innych kategorii wiekowych.

4.6 Development

W celu ulepszenia naszego systemu zdecydowaliśmy się na próbę dodatkowego dotrenowania modelu. Uznamyliśmy, że jest to najbardziej naturalne podejście, które pozwoli modelowi lepiej „spodziewać się” efektów starzenia twarzy.

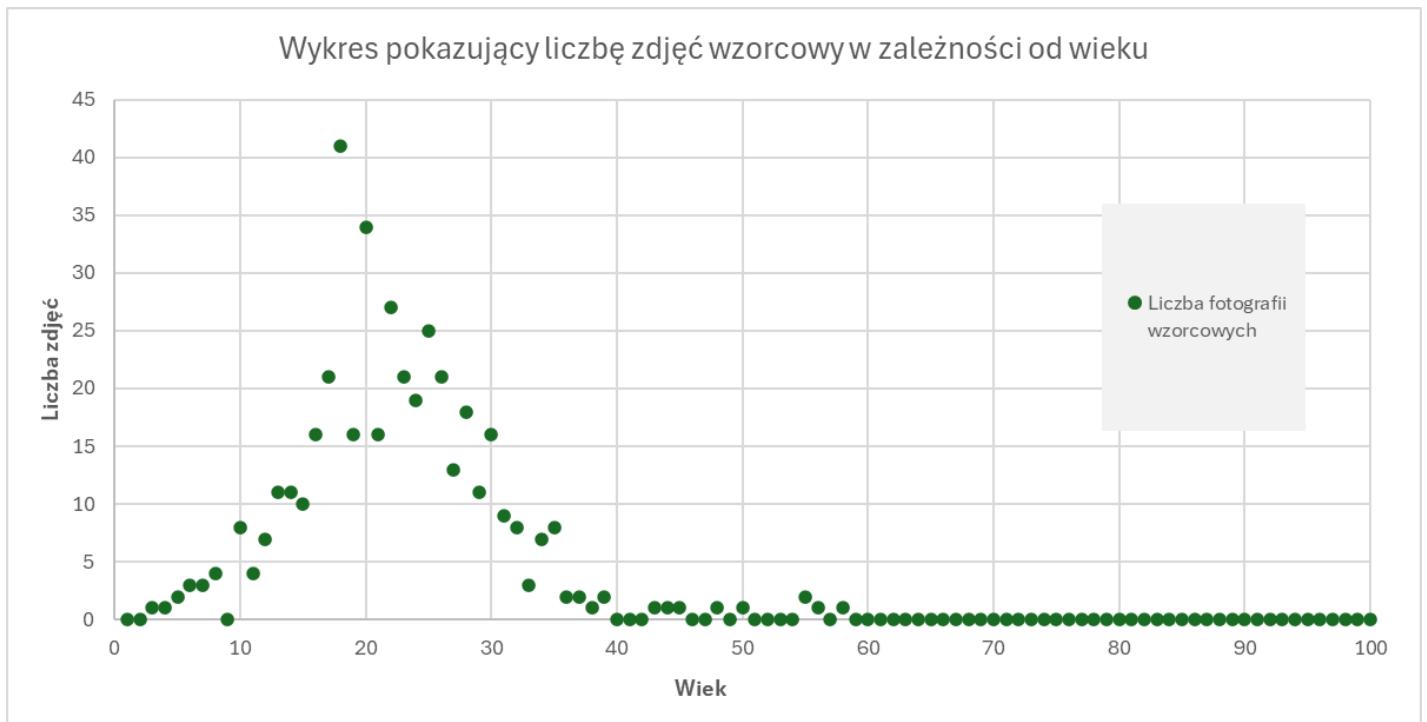
Na proces trenowania poświęciliśmy kilka dni. Niestety, mimo licznych prób, nie udało się obniżyć funkcji straty (loss) poniżej wartości 6. Prawdopodobną przyczyną był ograniczony zbiór danych twarzy lub nieoptymalny dobór parametrów treningu.

W związku z tym postanowiliśmy skorzystać z gotowych modeli udostępnionych przez twórców biblioteki FaceX-Zoo. W naszym projekcie zastosowaliśmy model oparty na architekturze ResNet152-IRSE. Wymagało to również ręcznej modyfikacji klasy ModelLoader, tak aby prawidłowo wczytywała i inicjalizowała nasz model.

4.7 Badanie działania ulepszeń

Po wprowadzeniu nowego modelu ogólna skuteczność rozpoznawania twarzy wzrosła do 70%. Model zaczął znacznie lepiej radzić sobie z rozpoznawaniem twarzy osób starszych.

Na wykresie poniżej (Rysunek 6) przedstawiono liczbę użytych zdjęć wzorcowych z podziałem na wiek osoby przedstawionej na fotografii.



Rysunek 6: Liczba wzorcowych fotografii z podziałem na wiek

Każdej osobie badanej przypisano jedno zdjęcie wzorcowe. Jak można zauważyć, zdjęcia te pochodzą głównie z przedziału wiekowego 10–30 lat.

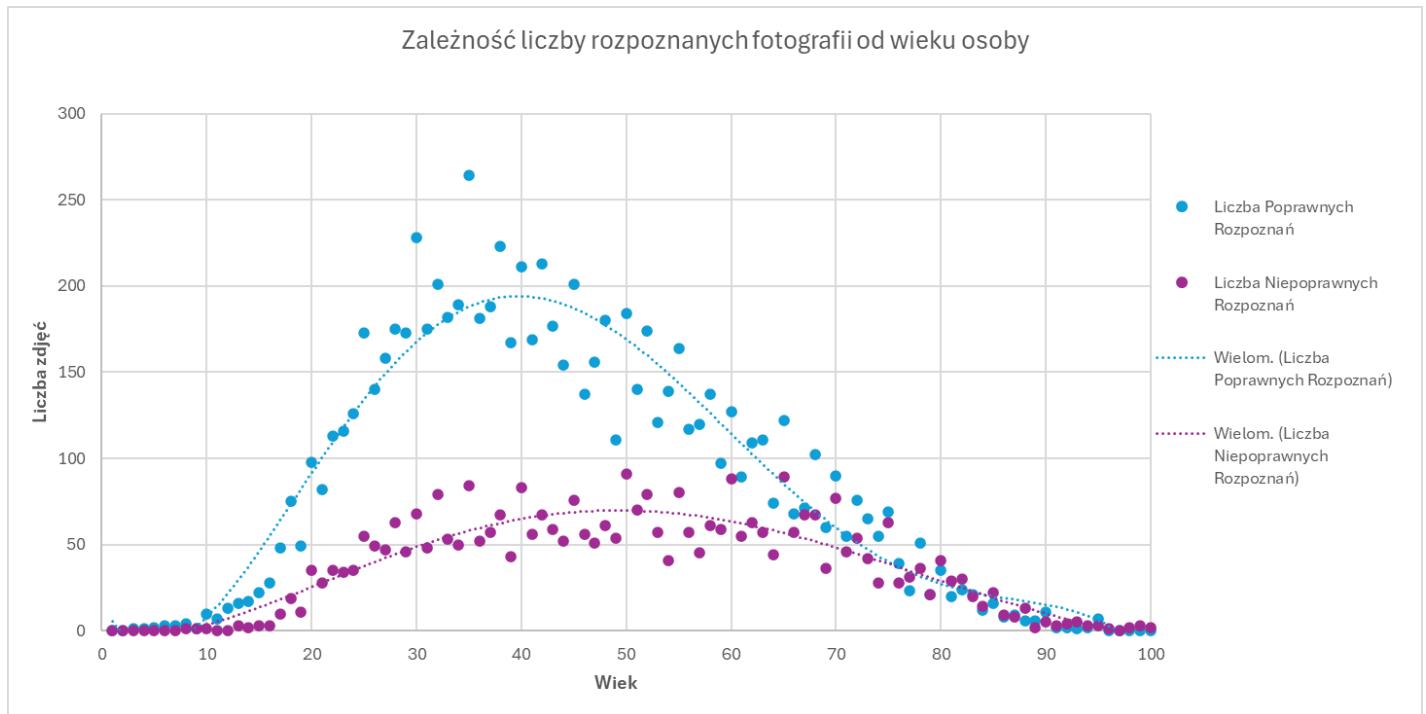
Następnie przebadano wszystkie zdjęcia z bazy danych w celu rozpoznania znajdujących się na nich twarzy. Wyniki tej analizy przedstawiono w Tabeli 3.

Uzyskany wynik 70% stanowi istotną poprawę w porównaniu do 44%, które uzyskano wcześniej przy użyciu standardowego modelu. Pozytywnym aspektem jest również fakt, że tylko 97 fotografii zostało błędnie przypisanych do zupełnie innej osoby.

Dokładny rozkład liczby poprawnie i błędnie rozpoznanych twarzy w zależności od wieku przedstawia Rysunek 7.

Opis	Liczba zdjęć
Wszystkie zdjęcia	12 018
Rozpoznane	8 413
Nierozpoznane	3 605
z błędnią klasyfikacją	97
Ogólna skuteczność	70%

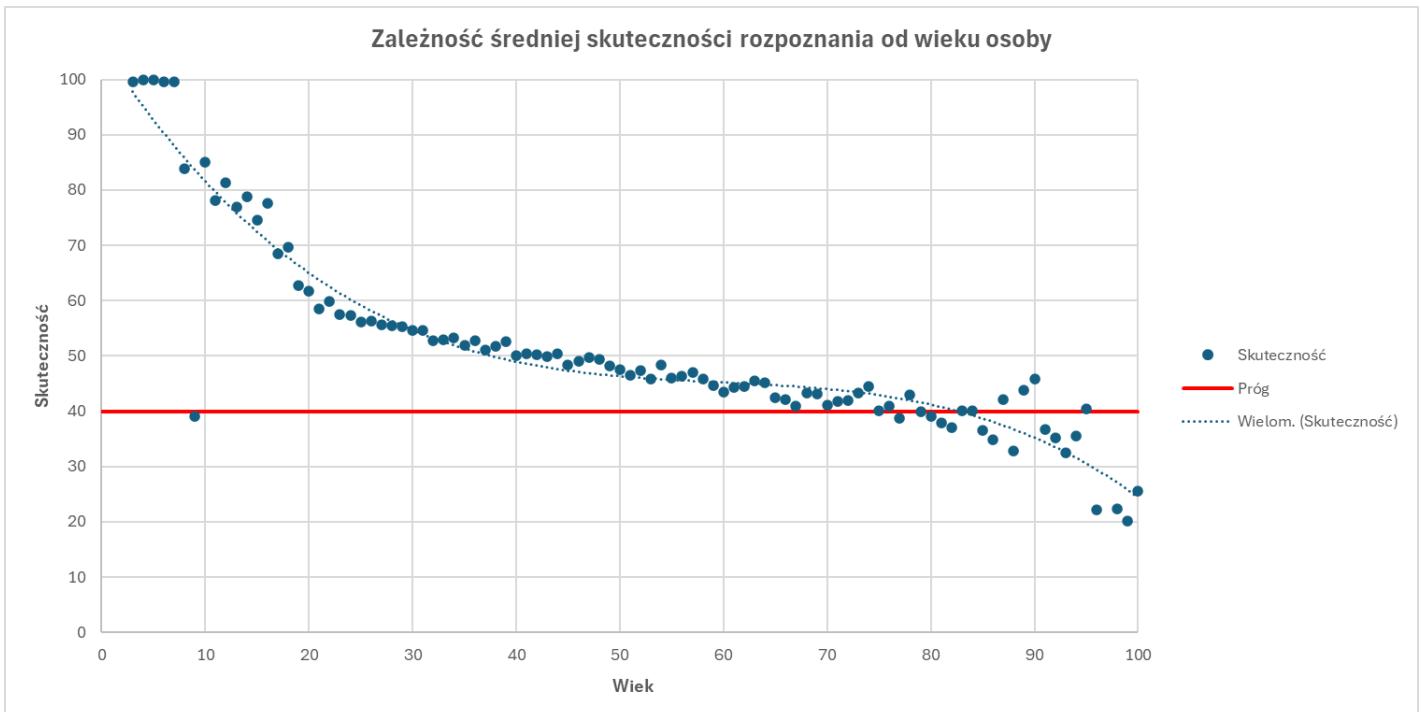
Tabela 3: Podsumowanie wyników rozpoznawania twarzy



Rysunek 7: Liczba rozpoznanych i nierożpoznanych twarzy w zależności od wieku

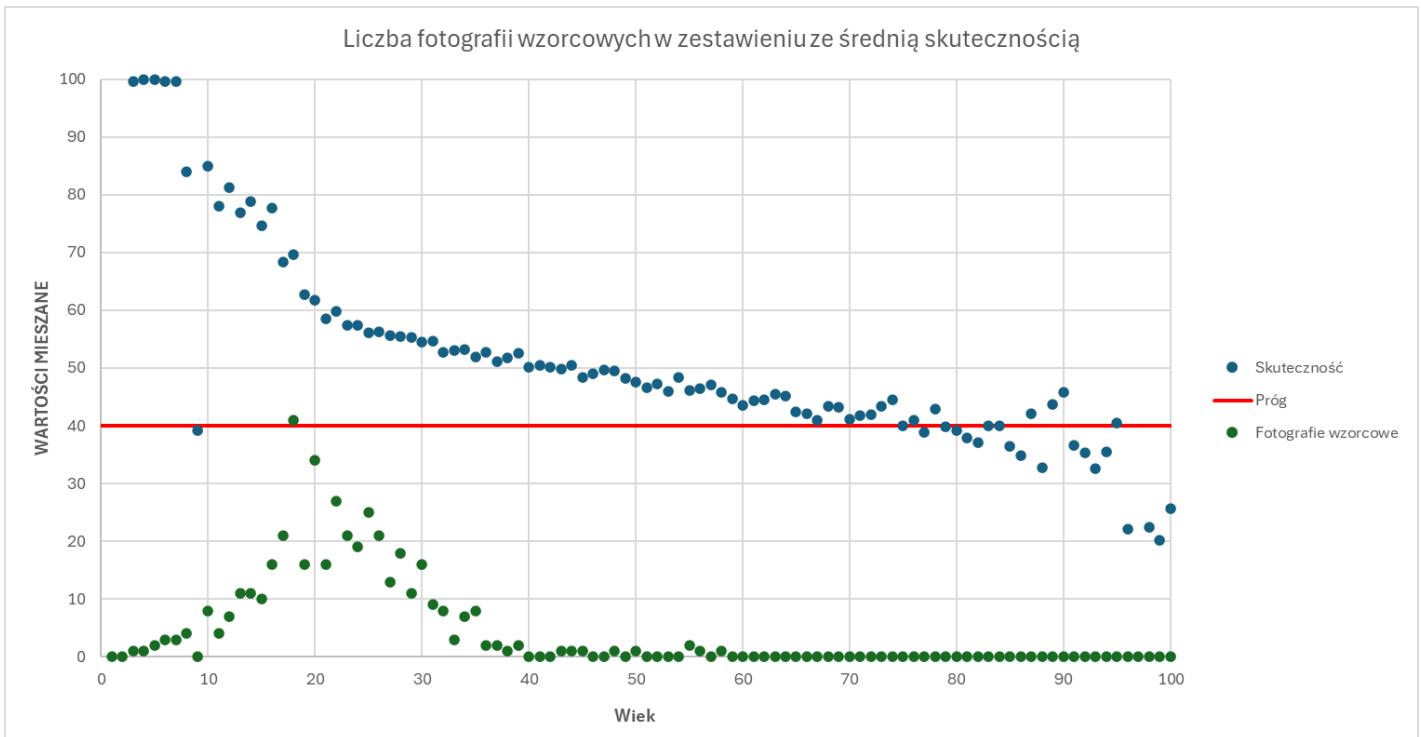
Z wykresu można odczytać, że model najlepiej radził sobie w zakresie wieku od 0 do około 55 lat — w tym przedziale liczba rozpoznanych twarzy była wyraźnie większa niż nierożpoznanych. Natomiast w grupie wiekowej 70–80 lat liczba przypadków nierożpoznania przewyższała liczbę skutecznych rozpoznań.

Na kolejnym wykresie (Rysunek 8) przedstawiono średnią skuteczność rozpoznania w zależności od wieku osoby. Wartość ta odpowiada średniemu poziomowi podobieństwa pomiędzy wektorem cech uzyskanym ze zdjęcia a odpowiadającym mu wektorem ze zbioru wzorców.



Rysunek 8: Średnia skuteczność rozpoznania twarzy w zależności od wieku

Jak można zauważyć, wraz ze wzrostem wieku skuteczność rozpoznania systematycznie maleje. Przyczyną tego zjawiska jest fakt, że zdjęcia wzorcowe pochodzą z najmłodszych dostępnych lat życia badanych. Zależność ta została zilustrowana również na Rysunku 9, gdzie zestawiono rozkład wiekowy zdjęć wzorcowych oraz średnią skuteczność w rozpoznawaniu. Z analizy wynika, że model całkiem dobrze radzi sobie z rozpoznawaniem twarzy nawet do około 40 lat różnicy względem zdjęcia wzorcowego. Niestety, dla wieku powyżej 70–80 lat skuteczność rozpoznania często spada poniżej przyjętego progu (40% podobieństwa wektorów cech).



Rysunek 9: Zestawienie liczby zdjęć wzorcowych i średniej skuteczności w zależności od wieku

4.8 Wnioski końcowe

Porównując wyniki uzyskane przed zastosowaniem ulepszeń z rezultatami po ich wdrożeniu, można zauważać wyraźną poprawę jakości rozpoznawania twarzy. Model zyskał zdolność identyfikacji osób nawet przy różnicy wieku sięgającej około 40 lat, podczas gdy wcześniej skuteczność ograniczała się głównie do przedziału 20 lat.

Jednak mimo ogólnej poprawy, skuteczność systemu nadal utrzymuje się na poziomie około 70%, co może być spowodowane obecnością wielu zakłóceń w danych. Do najczęstszych należą: częściowe zasłonięcie twarzy, obecność okularów czy zmiany fryzury. Czynniki te znaczowo wpływają na spójność cech twarzy wykorzystywanych przez algorytm.

Zaobserwowałyśmy również, że aplikacja FaceApp, wykorzystywana do sztucznego starzenia zdjęć, może nie w pełni odwzorowywać naturalne procesy starzenia. Prawdopodobnie stosowany algorytm nie modyfikuje istotnie układu charakterystycznych punktów twarzy (landmarków), co skutkuje tylko nieznaczną zmianą wektora cech. W efekcie sztucznie postarzone zdjęcia są rozpoznawane łatwiej niż naturalnie postarzałe w bazie AgeDB.

W przyszłości planujemy ponownie podejść do trenowania modelu, z nadzieją na osiągnięcie lepszych rezultatów. Ciekawym kierunkiem rozwoju może być także wykorzystanie zdjęć przetworzonych przez FaceApp jako dodatkowych wzorców przy rozpoznawaniu starszej wersji twarzy tej samej osoby.

Podsumowując, nasz system wykazuje poprawę w zakresie odporności na efekt starzenia, lecz nadal istnieje potencjał do dalszej optymalizacji — zarówno poprzez rozszerzenie bazy treningowej, jak i modyfikację architektury czy strategii treningowej modelu.

4.9 Instrukcja Użytkownika i Instalacji

Wymagania systemowe:

- System operacyjny Windows/Linux
- Karta graficzna NVIDIA z obsługą CUDA (zalecane)
- Python 3.9 lub nowszy

Instalacja:

1. Sklonuj repozytorium FaceX-Zoo
2. Zainstaluj wymagane biblioteki:CopyDownload

```
pip install PySide6 opencv-python numpy pip install torch
torchvision torchaudio --index-url https://download.pytorch.org/whl/cu118
```

3. Przejdź do folderu projektu:CopyDownload

```
cd FaceX-Zoo-main/face_sdk
```

Uruchomienie systemu:

```
python live_usage/gui_face_recognition.py
```

Dodawanie nowych twarzy:

1. W folderze faces_db utwórz podfolder z imieniem i nazwiskiem osoby (np. Jan_Kowalski)
2. Umieść w nim zdjęcia twarzy (w formacie JPG/PNG)
3. Zdjęcia powinny pokazywać twarz frontalnie, z dobrym oświetleniem

Obsługa interfejsu:

- Wybierz źródło obrazu (kamera/plik) w górnym menu
- Wyniki rozpoznawania wyświetla się na ekranie w czasie rzeczywistym
- Statystyki i logi zapisywane są automatycznie w folderze logs

5 Bibliografia

- https://www.researchgate.net/figure/dentification-of-facial-landmarks-using-Dlib-a-Facial-landmarks-b-The-position-and_fig2_343699139
- <https://arsfutura.com/blog/face-recognition-with-facenet-and-mtcnn>
- <https://pyimagesearch.com/2018/09/24/opencv-face-recognition/>
- https://github.com/JDAI-CV/FaceX-Zoo/tree/main/face_sdk
- <https://github.com/serengil/deepface>
- <https://arxiv.org/pdf/2101.04407>
- <https://ibug.doc.ic.ac.uk/resources/agedb/>